

基于深度学习的马铃薯叶片病害检测方法^{*}

赵越, 赵辉, 姜永成, 任东悦, 李阳, 卫勇

(天津农学院工程技术学院, 天津市, 300384)

摘要:植物病害对食品安全具有灾难性的影响,它可以直接导致农作物的质量和产量显著下降,因此对植物病害的早期鉴定非常重要。传统的农作物病害诊断需要非常高的专业知识,不仅费时费力,还效率低下。针对这些问题,利用深度学习的方法,以马铃薯叶片为研究样本,基于 TensorFlow 开发 Faster R-CNN 网络模型。采用本地增强的方式对带有早疫病、晚疫病和健康的马铃薯叶片进行图像扩充,应用 COCO 初始权重进行迁移学习,探究了数据类别对模型检测结果的影响。结果表明,随着训练数据类别的增多模型性能会有略微的降低。同时还训练 YOLOv3, YOLOv4 网络与该模型进行对比,测试结果表明,所提出的 Faster R-CNN 模型优于其他网络模型。经检测该模型最佳精度达到 99.5%,该研究为马铃薯病害检测提供了技术支持。

关键词:植物病害;深度学习;Faster R-CNN;迁移学习;病害检测

中图分类号:S24; TP391.4 **文献标识码:**A **文章编号:**2095-5553(2022)10-0183-07

赵越, 赵辉, 姜永成, 任东悦, 李阳, 卫勇. 基于深度学习的马铃薯叶片病害检测方法[J]. 中国农机化学报, 2022, 43(10): 183-189

Zhao Yue, Zhao Hui, Jiang Yongcheng, Ren Dongyue, Li Yang, Wei Yong. Detection method of potato leaf diseases based on deep learning [J]. Journal of Chinese Agricultural Mechanization, 2022, 43(10): 183-189

Detection method of potato leaf diseases based on deep learning

Zhao Yue, Zhao Hui, Jiang Yongcheng, Ren Dongyue, Li Yang, Wei Yong

(College of Engineering and Technology, Tianjin Agricultural University, Tianjin, 300384, China)

Abstract: Plant diseases can have a disastrous impact on food safety. They can directly lead to a significant decrease in the quality and yield of crops. Therefore, early identification of plant diseases is very important. Traditional crop disease diagnosis requires very high professional knowledge, not only time-consuming and laborious, but also inefficient. In this paper, we use the method of deep learning to develop the Faster R-CNN network model based on TensorFlow, and taking potato leaves as research samples. We expanded the image of potato leaves with early blight, late blight and health by local enhancement method. The COCO initial weight was applied for transfer learning, and the influence of data categories on model detection results was explored. The results showed that with the increase of training data categories, the performance of the model would be slightly reduced. At the same time, we also trained YOLOv3 and YOLOv4 network to compare with this model. The test results showed that the performance of our proposed Faster R-CNN model was better than other network model, and the best accuracy of the model reached 99.5% after testing. This study can provide technical support for potato disease detection.

Keywords: plant disease; deep learning; Faster R-CNN; transfer learning; disease detection

0 引言

植物病害在世界范围内给农业部门造成了巨大的

损失,因此及时、准确地诊断植物病害对于可持续农业的正确发展具有重要意义^[1]。马铃薯是仅次于玉米、小麦和水稻的世界第四大农业粮食作物,它可以减少

收稿日期:2021年6月9日 修回日期 2021年8月11日

^{*} 基金项目:天津市科技计划项目(19YFZCSN00360);天津市企业科技特派员项目(20YDTPJC01340)

第一作者:赵越,男,1997年生,河北保定人,硕士研究生;研究方向为农业智能化检测。E-mail: gta5498@126.com

通讯作者:卫勇,男,1973年生,山西浮山人,博士,副教授;研究方向为智能农机装备。E-mail: weiyjtj@tjau.edu.cn

血液中胆固醇的总量,有助于治疗高血压、心脏病和癌症等疾病^[2]。然而,马铃薯的产量下降深受植物病害的影响。目前为止,经验丰富的生产者的目视观察仍然是发展中国家农村地区植物病害检测的主要方法。此方法需要专家的持续监测,而在一些偏远的地区,农民们可能要走很远的路才能联系专家,这使得咨询费时费力^[3]。

在过去的几年里,深度学习已经解决了越来越多的复杂任务,并且准确率越来越高。人们对这类技术的兴趣在于其在农业方面的潜在应用,推动高效自主系统的发展,而植物病害的自动识别就是其中一个重要的研究内容。2018 年 Ferentinos^[4]使用了开放数据库对多种植物病害图像进行训练,成功搭建了综合植物病害识别系统,实现了简单的卷积神经网络病害图像自动检测和植物疾病诊断;2019 年 Saleem 等^[5]对植物病害可视化的深度学习模型进行了综述,研究了在植物症状明显之前,如何检测可以获得更大的透明度;2021 年 Atila 等^[6]使用 Plant Village 数据集通过迁移学习的方式训练了 EddicientNet 架构和其他主流的深度学习网络模型,通过不同网络模型的对比,EfficientNet 架构的检测精度最高,提出了一种用于植物叶片病害分类的高精度深度学习网络结构。

从上述的研究可以看出,深度学习在植物叶片病害检测中有所增加。然而,在利用新的深度学习网络结构进行植物叶片病害检测及应用方面,仍缺乏研究。尤其是对网络结构小,训练速度快,检测精度高的模型有强大的需求。因此,本文基于 TensorFlow 开发了 Faster R-CNN 深度学习网络模型^[7],并利用多个分类器检测马铃薯叶片疾病,成功实现了马铃薯叶片病害的高精度检测。

1 材料与方法

1.1 试验材料

本文采用 Kaggle 国际竞赛开源的数据库^[8],其中包含了各种植物病害的图片,如玉米、葡萄、番茄、苹果等。图片储存为 jpg 格式。本文选取马铃薯叶片为样本,其中单张图片的像素为 256×256 ,包含了早疫病、晚疫病和健康的图片。使用 LABELIMG 图像图形注释工具对图片进行标注^[9]。由 3 个具有标注经验的专家完成,每个病害或者健康的叶片都由一个矩形框包含,并且再次进行标注检查,避免漏标错标的可能性。将标注好的图片保存在 XML 文件中,其中包含了边框的位置坐标。在这个文件中,bounding box 被保存为一个 4 元组 $(x_{\min}, y_{\min}, x_{\max}, y_{\max})$,其中 (x_{\min}, y_{\min}) 表示 bounding box 的左上角坐标,而对应的 (x_{\max}, y_{\max})

则表示包围盒的宽度和高度,如图 1 所示。



图 1 标注的马铃薯叶片图像

Fig. 1 Annotated potato leaf image

1.2 数据增强

为了解决数据集小、图像缺乏多样性的问题,本文采用本地增强的方式对数据集进行扩充,采用 4 种随机增强的方式,包括平移、旋转、镜像这些变换来改变标注矩形框的位置信息,增加了植物病害图像的多样性。为了消除光照对图像的影响,通过改变亮度的方式对图像进行了变换,模拟出了不同光照下植物病害的生长情况。经过数据增强后的马铃薯叶片图像为 8 109 张,并按照 7 : 2 : 1 的比例分为了训练集、验证集和测试集,每种类别的数量如表 1 所示。

表 1 数据增强后的马铃薯叶片数据集
Tab. 1 Data augment of potato leaf data set

类别	训练集	验证集	测试集	合计
早疫病	1 680	480	240	2 400
晚疫病	1 680	480	240	2 400
健康	2 316	660	333	3 309
合计	5 676	1 620	813	8 109

2 网络结构

2.1 Faster R-CNN 网络

Faster R-CNN^[7]是目标检测领域主流的算法之一,相比 YOLO 算法^[10],其检测精度更高。本文的整体网络结构如图 2 所示,首先在子图像中搜索潜在的候选对象,因此需要一个区域建议(region proposal)的方法。将子图像输入到卷积神经网络中(CNN),进行特征提取^[11]。区域建议网络(RPN)^[12]在输入的子图像上生成多个密集的先验框(anchors)区域网格,具有指定的大小和纵横比。裁剪过滤后通过 softmax 函数来判断先验框属于前景或者背景,同时用另一个边界框回归(bounding box regression)来修正先验框,形成精确的建议框。然后把建议框映射到 CNN 最后一层卷积的特征图谱(feature map)上,并通过 ROI pooling 层使每个感兴趣区域(ROI)在特征图谱上生成固定的尺寸。如果先验框与真实物体的交并比 $IoU^{[13]}$ 大于一个相对较大的重叠阈值,则该先验框被赋为正,反之则被赋为负。由卷积神经网络(CNN)组成的区域建议网络(RPN)预测每个病害的分数,从而检测其为某种

病害的概率,这种方法的优点是模型有效地学习了图像的背景特征,从而消除了分类步骤中的负面位置。

2.1.1 特征提取

本文选取 VGG16^[14] 的卷积神经网络对马铃薯叶片图像进行特征提取,模型包括 13 个卷积层、4 个池化层和 13 个 Relu 激活函数层。以 $224 \times 224 \times 3$ 为固

定尺寸作为图像的输入,全部使用 3×3 的卷积核以及 2×2 的池化核,前 4 个卷积层主要提取目标的浅层特征,保留初始参数。后 9 个卷积层进行迁移学习,提取目标更深层次的特征。网络结构以及卷积变换如图 3 所示,经过卷积处理后得到特征图谱,在特征图谱上每一个像素点对应原图上的某一个区域。

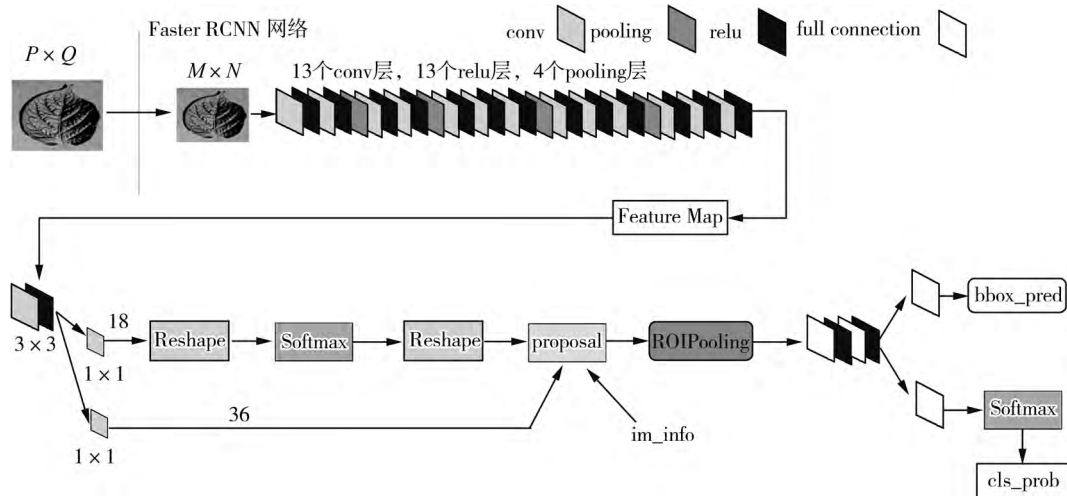


图 2 Faster R-CNN 网络结构

Fig. 2 Network structure of Faster R-CNN

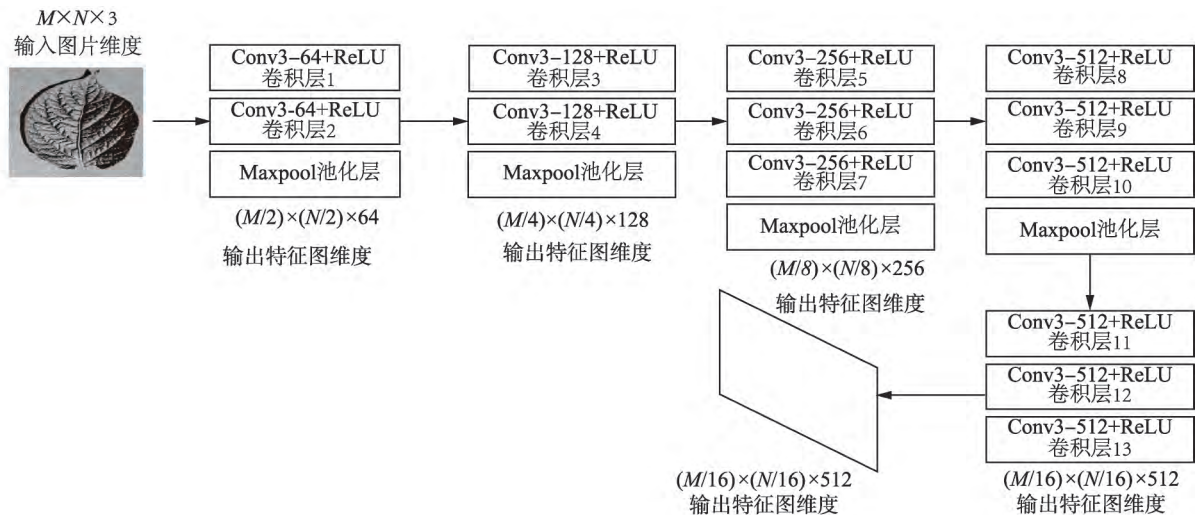


图 3 VGG16 网络卷积变换

Fig. 3 VGG16 network convolution transformation

2.1.2 RPN 网络

RPN 网络连接在卷积的特征提取之后,将卷积后的特征图谱上的点与原图像的位置对应,并以每个点为中心作为滑动窗口,生成区域建议框,如图 4 所示。

经过滑动窗口的处理,每个滑动窗口都映射到一个低维向量上^[15],这个向量输出到同一级别的两个全连接层,即边界框的回归层和边界框的分类层,然后通过两次全连接得到 2 000 个分数和 4 000 个坐标。

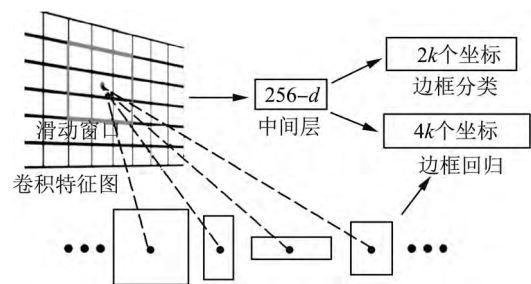


图 4 RPN 网络结构

Fig. 4 Network structure of RPN

2.2 回归分类

经过 RPN 网络处理,得到很多个目标候选区域,而 ROI Pooling 的作用就是把大小形状各不相同的候选识别区域归一化为固定尺寸的目标识别区域^[16]。分类层利用已经获得的候选特征图谱,经过全连接层和 softmax 函数计算每个候选区域属于哪个类别,以及输出这个类别的概率,同时再次利用边界框回归来获得每个候选区域与真实背景位置的偏移量,用于回归计算更加精准的检测框及其置信度。置信度^[17]的公式见式(1)。

$$\begin{aligned} \text{Confidence} &= P_r(\text{Object}) \times \text{IoU}_{\text{pred}}^{\text{truth}}, \\ P_r(\text{Object}) &\in [0, 1] \end{aligned} \quad (1)$$

式中: P_r ——预测含有对象的概率;

IoU ——预测框和真实框的交并比值。

预测目标的结果为 $[0, 1]$ 。其中 0 表示检测到目标的最低置信度,1 表示最高置信度。本文中选用置信度为 0.5,因为它提供了两种情况之间令人满意的权衡结果。

3 试验

3.1 训练环境

本试验中使用 Intel(R) Xeon(R) CPU E5-2650v4 的处理器, GPU 为 GeForce RTX 2080Ti 加速模型训练。采用 python3.6, 基于 TensorFlow2.2.0-gpu 开发的 Faster R-CNN 深度学习模型框架。将 RPN 层插入到第 4 个卷积层和第 5 个卷积层之间,并且在 RPN 层中的每个位置都设置了一个先验框。按照默认设置,在每个位置分配了 12 个不同大小、不同长宽比的先验框。如果先验框和标注的马铃薯病害叶片间的 IoU 在 0.5~1.0 之间,则认为马铃薯存在某种病害。Batch size 大小固定为 1,它节省了计算时间和内存需求。每个包围框都与一个分数值相关联。用 0.5 的置信度阈值来判断一个包围框是否存在病害或者健康。

3.2 模型训练

一个模型的精准度可以通过观察模型在学习过程中的训练损失值和错误率来分析。该模型采用 COCO 数据集^[18]的初始权重,对训练集上的 5 676 张图片进行了预训练,并根据验证集上的图片调整网络超参数,经过几个时期后,它们逐渐减少错误率和训练损失值,接近它们的最终值,图 5 和图 6 分别展示了模型训练损失值以及准确率的变化。虽然最初损失值和错误率都很高,但在每个训练阶段之后错误率的降低伴随着模型检测精度的提高^[19]。根据不断的试验,为了避免模型过拟合,将 epoch 的数目固定在 200,最终以 0.0001 的学习率和 0.9 的动量模型达到收敛,最后在测试集上进行

测试,模型的最佳检测精度达到了 99.5%。




图 5 模型损失值的变化

Fig. 5 Change of model loss values




图 6 模型准确率变化

Fig. 6 Change of model accuracy

3.3 评价标准

根据模型检测真正类别和预测类别的组合,样本可以分为真正(TP)、假正(FP)、真负(TN)和假负(FN)4 种类型^[20]。其中 TP 是实际上属于类 C 并被模型正确识别的实例数量,而 FN 则相反,它是属于类 C 但被错误分类的实例数量, TN 是实际不属于类 C 的实例数量,并且他们被正确识别, FN 是不属于类 C 但被错误识别为类 C 的实例数量。通过正确检测和错误检测的统计,用精度($Precision$)、召回率($Recall$)和准确性($Accuracy$)和模型评分($F1-Score$)来评价模型的性能^[21],其定义如下

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

$$F1-Score = 2 \times \frac{Precision \cdot Recall}{Precision + Recall} \quad (5)$$

IoU (Intersection over Union)^[13] 全称为交并比,是计算目标对象检测精度的标准,通过计算预测的边

界框和真实边界框的重叠率来评估模型的性能,其定义如下

$$IoU = \frac{S_{\text{overlap}}}{S_{\text{union}}}$$

(6)

式中: S_{overlap} —— 预测边框和真实边框相交的区域;
 S_{union} —— 两个边框并集的区域。

AP (Average Accuracy)衡量的是模型在每个类别上训练的好坏, mAP (Mean Average Accuracy)^[22]衡量的是训练出来的模型在所有类别上的好坏, mAP 意义上是取所有类别上 AP 的平均值。其中 AP , mAP 的定义如下

$$AP = \int_0^1 P(r) dr$$

(7)

$$mAP = \frac{\sum_{i=1}^N AP_i}{N}$$

(8)

式中: $P(r)$ —— 召回测量的精度;
 N —— 目标分类的数目。

本文使用 $mAP@0.5$ 表示置信度以 0.5 为标准的目标检测平均准确率。

4 结果与讨论

4.1 马铃薯叶片检测

利用训练好的权重文件对测试集上带有早疫病、晚疫病、健康的马铃薯叶片分别作了检测,其中测试了 333 张健康的马铃薯叶片,有 1 张图像被错误检测,识别率为 99.7%;测试了 240 张早疫病的图片,同样有 1 张图片被错误检测,识别率为 99.5%;测试了 240 张晚疫病的图片,有 2 张图片被错误检测,识别率为 99.2%。模型的最佳精度达到了 99.5%。检测结果如图 7 所示。




图 7 马铃薯叶片检测结果
Fig. 7 Test results of potato leaves

4.2 数据类别对模型的影响

为了比较数据类别对检测结果的影响,使用 Faster R-CNN^[9]对早疫病、晚疫病和健康的马铃薯叶片图像分别进行训练,并且和病害、健康混合训练的

模型进行了对比,训练后模型的 $P-R$ (Precision-Recall) 曲线^[23]如图 8 所示,对应的 $F1-Score$ 如表 2 所示。从图 8 可以看出,模型的精度随着召回率的增加而不断降低,最小收敛精度在 0.95 左右。通过比较模型的性能,在同一精度下,任意单类别训练模型的召回率要高于混合训练的模型;在同一召回率下,任意单类别训练的模型精度也要高于混合训练的模型。同样,从表 2 可以看出,健康模型 $F1-Score$ 值最高为 0.961,晚疫病模型最低也达到了 0.953,而组合训练模型仅达到 0.951。不论是精度、召回率还是 $F1-Score$,任意单类别训练模型都要高于混合训练模型。这表明了输入类别数量的增多会导致模型性能的降低。

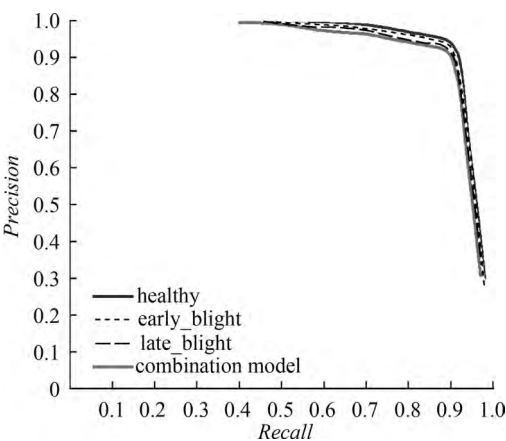


图 8 不同类别下的 $P-R$ 曲线
Fig. 8 $P-R$ curves under different categories

表 2 不同类别下的模型表现
Tab. 2 Model performance at different categories

类别	$F1-Score$
健康	0.961
早疫病	0.957
晚疫病	0.953
组合模型	0.951

4.3 不同网络模型的比较

为了验证所提出的 Faster R-CNN 模型的性能,同时训练了 YOLOv3^[24], YOLOv4^[25] 与该模型进行对比,每种模型都达到了最大程度的收敛($AP@0.5IoU$),训练完成模型的 $P-R$ 曲线如图 9 所示,对应的 $F1-Score$, IoU 和 mAP 如表 3 所示。

由图 9 可以看出,在同一精度下, Faster R-CNN 的召回率要高于其他两种网络模型;在同一召回率下, Faster R-CNN 的精度也高于其他两种网络模型。从表 3 可以看出,对比 $F1-Score$, Faster R-CNN 的值最高为 0.951。这表明了 Faster R-CNN 的综合召回性能和精度要优于其他两种网络模型。同样, Faster

R-CNN的 IoU 值最高达到了 0.957, mAP 值最高为 0.965, 均高于其他两种网络模型, 这表明了不论是检测包围盒准确率还是模型的类平均精度, Faster R-CNN 都是最优的。对于检测速度 Faster R-CNN 作为双阶段网络要低于其他单阶段网络模型, 但仍然满足实时性检测的需求。通过对比不同网络模型的性能, Faster R-CNN 展现出了更优的潜力。

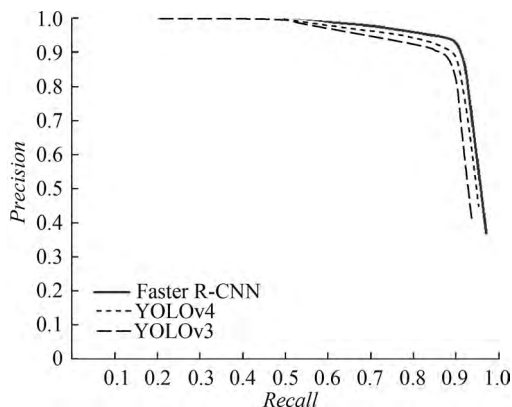


图 9 不同网络模型下的 P-R 曲线

Fig. 9 P-R curves under different network models

表 3 不同网络模型的性能表现

Tab. 3 Performance of different network models

方法	$F1-Score$	IoU	mAP	检测速度/FPS
Faster R-CNN	0.951	0.957	0.965	9
YOLOv4	0.946	0.95	0.961	47
YOLOv3	0.938	0.943	0.95	52

5 结论

1) 本文提出了一个马铃薯叶片病害自动检测的模型, 解决了传统病害检测专业性高、费时费力的问题。该模型包含了马铃薯叶片的早疫病、晚疫病和健康的图像。

2) 通过对马铃薯叶片早疫病、晚疫病和健康的图像单独训练和混合训练模型的对比, 不论是精度、召回率、 $F1-Score$ 值单独训练的模型都要高于混合训练的模型, 表明了输入图像类别的数量会对检测结果产生偏差, 随着类别数量的增多, 模型的检测性能略有降低。

3) 训练了 YOLOv3、YOLOv4 网络模型与该模型进行对比, 结果表明, 该模型的性能优于其他网络模型。本文模型的 $F1-Score$ 值为 0.951, IoU 为 0.957, mAP 为 0.965。该模型的最佳检测精度达到了 99.5%, 为农民早期发现疾病, 提高作物的产量提供了技术支持。

4) 在未来的工作中, 将进一步对模型识别病害的种类进行扩展, 将其发展为多种作物不同病害识别系统。并从实际生活中的不同地域、不同环境采集更多

的数据来设置更广泛的训练。与此同时, 将对 Faster R-CNN 中的 RPN 网络进行优化, 保证精确度的同时, 通过降低计算量的方式, 来提升网络的检测速度。

参 考 文 献

- [1] Chen J D, Chen J X, Zhang D F, et al. Using deep transfer learning for image-based plant disease identification [J]. Computers and Electronics in Agriculture, 2020, 173(2): 1-11.
- [2] 谢从华. 马铃薯产业的现状与发展[J]. 华中农业大学学报(社会科学版), 2012(1): 1-5.
Xie Conghua. Potato industry: Status and development [J]. Journal of Huazhong Agricultural University (Social Sciences Edition), 2012(1): 1-5.
- [3] Militante S V, Gerardo B D, Dionisio N V. Plant leaf detection and disease recognition using deep learning [C]. 2019 IEEE Eurasia Conference on IOT, Communication and Engineering (ECICE). IEEE, 2019.
- [4] Ferentinos K P. Deep learning models for plant disease detection and diagnosis [J]. Computers and Electronics in Agriculture, 2018, 145: 311-318.
- [5] Saleem M H, Potgieter J, Arif K M. Plant disease detection and classification by deep learning [J]. Plants, 2019, 8(11): 468.
- [6] Atila U, Ucar M, Akuol K, et al. Plant leaf disease classification using EfficientNet deep learning model [J]. Ecological Informatics, 2021, 61: 1-21.
- [7] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1137-1149.
- [8] Abdallah Ali. PlantVillage dataset [EB/OL]. <https://www.kaggle.com/abdallahalidev/plantvillage-dataset>, 2019-09-06.
- [9] Darrenl. labelImg is a graphical image annotation tool and label object bounding boxes in images [EB/OL]. <https://github.com/tzutalin/labelImg>, 2017-04-03.
- [10] 周晓彦, 王珂, 李凌燕. 基于深度学习的目标检测算法综述[J]. 电子测量技术, 2017, 40(11): 89-93.
Zhou Xiaoyan, Wang Ke, Li Lingyan. Review of object detection based on deep learning [J]. Electronic Measurement Technique, 2017, 40(11): 89-93.
- [11] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6): 1229-1251.
Zhou Feiyan, Jin Linpeng, Dong Jun. Review of convolutional neural network [J]. Chinese Journal of Computers, 2017, 40(6): 1229-1251.
- [12] 张汇, 杜煜, 宁淑荣, 等. 基于 Faster RCNN 的行人检测方法[J]. 传感器与微系统, 2019, 38(2): 147-149, 153.
Zhang Hui, Du Yu, Ning Shurong, et al. Pedestrian detection method based on Faster RCNN [J]. Sensors and

- Microsystems, 2019, 38(2): 147–149, 153.
- [13] Xu Z, Shi H, Li N, et al. Vehicle detection under UAV based on optimal dense YOLO method [C]. 2018 5th International Conference on Systems and Informatics (ICSAI), 2018.
- [14] 罗浩伦, 冯泽霖, 冉钟南, 等. 基于 VGG16 网络的茶叶嫩芽自动检测研究[J]. 农业与技术, 2020, 40(1): 15–17.
- [15] 刘春池, 潘卫国. 基于 Faster RCNN 的行人检测[C]. 中国计算机用户协会网络应用分会. 2020 年第二十四届网络新技术与应用年会论文集[A]. 北京: 北京联合大学北京市信息服务工程重点实验室, 2020: 251–255.
- [16] 林刚, 王波, 彭辉, 等. 基于改进 Faster-RCNN 的输电线巡检图像多目标检测及定位[J]. 电力自动化设备, 2019, 39(5): 213–218.
- Lin Gang, Wang Bo, Peng Hui, et al. Multi-target detection and location of transmission line inspection image based on improved Faster-RCNN [J]. Electric Power Automation Equipment, 2019, 39(5): 213–218.
- [17] Xu D, Wu Y. Improved YOLO–V3 with DenseNet for multi-scale remote sensing target detection [J]. Sensors, 2020, 20(15): 4276.
- [18] Nalldrin, Krasin I, Pont-Tuset J, et al. The open images dataset [EB/OL]. <https://github.com/openimages/dataset>, 2016–11–03.
- [19] 李小占, 马本学, 喻国威, 等. 基于深度学习与图像处理的哈密瓜表面缺陷检测[J]. 农业工程学报, 2021, 37(1): 223–232.
- Li Xiaozhan, Ma Benxue, Yu Guowei, et al. Surface defect detection of Hami melon using deep learning and image processing [J]. Transactions of the Chinese Society of Agricultural Engineering, 2021, 37(1): 223–232.
- [20] 侯加林, 房立发, 吴彦强, 等. 基于深度学习的生姜种芽快速识别及其朝向判定[J]. 农业工程学报, 2021, 37(1): 213–222.
- Hou Jialin, Fang Lifa, Wu Yanqiang, et al. Rapid recognition and orientation determination of ginger shoots with deep learning [J]. Transactions of the Chinese Society of Agricultural Engineering, 2021, 37(1): 213–222.
- [21] Xie Y, Cai J, Bhojwani R, et al. A locally-constrained YOLO framework for detecting small and densely-distributed building footprints [J]. International Journal of Geographical Information Science, 2019, 34(4): 1–25.
- [22] Wu D, Lv S, Jiang M, et al. Using channel pruning-based YOLO v4 deep learning algorithm for the real-time and accurate detection of apple flowers in natural environments [J]. Computers and Electronics in Agriculture, 2020, 178: 1–12.
- [23] Tian Y, Yang G, Wang Z, et al. Apple detection during different growth stages in orchards using the improved YOLO–V3 model [J]. Computers and Electronics in Agriculture, 2019, 157: 417–426.
- [24] Redmon J, Farhadi A. YOLOv3: An incremental improvement [J]. Computer Vision and Pattern Recognition, 2018, 3(8): 22–27.
- [25] Bochkovskiy A, Wang C Y, Liao H. YOLOv4: Optimal speed and accuracy of object detection [J]. Computer Vision and Pattern Recognition, 2020(1): 1–16.